FACULDADE DE TECNOLOGIA DE FRANCA

“Dr. THOMAZ NOVELINO”

TECNOLOGIA EM DESENVOLVIMENTO SOFTWARE MULTIPLATAFORMA

ANA JÚLIA ALVES MOTA

LAUANE GABRIELA DE ARAÚJO TOLEDO

PEDRO HENRIQUE CINTRA SILVA

PROJETO INTEGRADOR

Relatório Final: DOEFÁCIL

FRANCA/SP

2026

1. Introdução

O **DoeFácil** é um sistema multiplataforma desenvolvido para otimizar a gestão e organização de campanhas, o gerenciamento de doações e o controle de estoque de instituições sociais. No contexto acadêmico da disciplina de Mineração de Dados do curso de Tecnologia em Desenvolvimento de Software Multiplataforma (DSM) da Fatec Franca, esta etapa final concentra-se na aplicação de análises exploratórias, tratamento de dados e aprendizado de máquina não supervisionado sobre uma base externa de instituições sociais.

A investigação utiliza dados públicos extraídos da API do projeto **Give Food**, que compila registros oficiais de bancos de alimentos e entidades assistenciais. O pipeline analítico foi estruturado para automatizar a limpeza, padronização e o agrupamento espacial (*clustering*) por meio de aprendizado de máquina, visando compreender a distribuição territorial das instituições e auxiliar na logística de doações.

2. Objetivos

O objetivo principal desta etapa de mineração de dados é aprofundar a análise espacial e a modelagem estatística de cadastros institucionais provenientes da base de dados do Give Food (`givefoodbasededados.json`). Especificamente, buscou-se:

- **Pré-processamento e Limpeza:** Automatizar a filtragem de registros ativos, validação de coordenadas geográficas (latitude e longitude) e eliminação de inconsistências por meio de scripts em Python.
- **Modelagem Espacial (K-Means):** Aplicar o algoritmo de agrupamento não supervisionado K-Means variando o número de clusters (k) de 2 a 6 para identificar padrões de concentração territorial.
- **Avaliação Comparativa de Desempenho:** Mensurar a qualidade das partições espaciais geradas utilizando métricas estatísticas oficiais, como o **Coeficiente de Silhueta**, o **Índice de Davies-Bouldin** e a **Inércia (Método do Cotovelo)**.

3. Metodologia

O pipeline analítico foi implementado em Python utilizando bibliotecas especializadas em manipulação de dados e aprendizado de máquina não supervisionado. O fluxo metodológico consistiu nas seguintes etapas:

- **Pré-processamento e Limpeza (`tratar.py`):**
  - Os dados brutos extraídos do arquivo `givefoodbasededados.json` foram carregados via Pandas para estruturação tabular.
  - O campo combinado de coordenadas geográficas (`lat_lng`) foi desmembrado em duas variáveis numéricas distintas: **latitude** e **longitude**.
  - Aplicou-se um filtro de elegibilidade rigoroso retendo apenas instituições com status ativo (`closed == False`), nomes válidos preenchidos e cujas coordenadas estivessem estritamente dentro dos limites globais válidos (latitude entre -90 e 90; longitude entre -180 e 180). O resultado consolidado foi gravado no arquivo `instituicoes_tratadas.csv`.
- **Modelagem Espacial via K-Means (`comparar_clusters.py`):**
  - Para identificar agrupamentos territoriais de forma automatizada, empregou-se o algoritmo **K-Means**, variando o número de clusters (k) de 2 a 6.
  - As variáveis descritivas utilizadas foram exclusivamente a latitude e a longitude. Para evitar distorções de escala entre os eixos geográficos, os dados foram normalizados com o `StandardScaler` (média zero e desvio padrão unitário).
  - Os hiperparâmetros globais foram fixados com `random_state=42` e `n_init=10` para assegurar a reprodutibilidade e a estabilização dos centroides.
- **Métricas de Avaliação de Desempenho:**
  - **Coeficiente de Silhueta:** Mensura a coesão interna dos clusters e a separação entre eles (valores mais próximos de +1 indicam partições bem definidas).

    - **Índice de Davies-Bouldin:** Avalia a similaridade entre o cluster e seu vizinho mais próximo (quanto menor o valor, melhor a separação).
    - **Inércia (Método do Cotovelo):** Soma das distâncias quadráticas das amostras até o centroide do cluster mais próximo, auxiliando na identificação do ponto de inflexão ideal para o parâmetro k.

4. Resultados e Discussão

A execução do script de comparação (`comparar_clusters.py`) processou com sucesso os registros validados, gerando métricas comparativas para cada valor de k testado e exportando o gráfico consolidado de desempenho (`comparar_metricas_clusters.png`).

- **Análise de Desempenho dos Agrupamentos ($k = 2$ a 6):**
    - **Inércia:** Apresentou a queda decrescente esperada à medida que o número de clusters aumentou, evidenciando o ganho progressivo de compactação espacial.
    - **Coeficiente de Silhueta e Davies-Bouldin:** Permitiram mapear o comportamento da distribuição geográfica das entidades assistenciais do Give Food, identificando qual partição k maximiza a separação territorial sem sobreposição excessiva entre os grupos de atendimento logístico.
    - O mapeamento visual gerado pelas coordenadas latitude/longitude permitiu evidenciar os principais eixos de concentração das instituições sociais, fornecendo suporte direto para o módulo de clusterização espacial e roteirização do DoeFácil.

5. Conclusão

A aplicação do pipeline de mineração de dados no projeto DoeFácil demonstrou ser altamente eficiente para estruturar e extrair inteligência territorial de bases de dados externas. O tratamento rigoroso dos dados garantiu a consistência das coordenadas geográficas, enquanto a modelagem via K-Means, apoiada por métricas de

validação como Silhueta e Davies-Bouldin, permitiu segmentar de forma ótima as instituições assistenciais.

Com esses resultados, o sistema DoeFácil ganha uma base analítica sólida para otimizar a distribuição de recursos, o planejamento de rotas de entrega e a gestão estratégica de campanhas solidárias, cumprindo integralmente os objetivos propostos na disciplina.